当代人工智能实验一：新闻文本分类

代码仓库：https://github.com/TinjiYDon/ai-exp1-text-classification

实验过程

1 读入数据

7368 篇有标签邮件
2457 篇待预测邮件

2 划分验证集

分层 80/20
5894 训练 / 1474 验证

3 学习 TF-IDF

只在 5894 篇上建词表

4 对照 18 组

三种模型各试三个参数
再比较删不删邮件头

5 按验证集锁定

macro-F1 最高：
线性 SVM，C=1

6 全量重训再交

用回全部 7368 篇
写出 prediction.csv

任务是把英文新闻组邮件分到 10 类。比较朴素贝叶斯、线性 SVM 和逻辑回归，并检验「删掉 From/Subject 会更干净」这个假设。选模型只看验证集 macro-F1。测试集没有标签，不参与挑选。
TF-IDF 使用最多 20000维、1–2 元词、英文停用词，random_state=42。

验证集上各模型最好的一档

朴素贝叶斯

0.905

alpha = 0.1

逻辑回归

0.937

C = 10

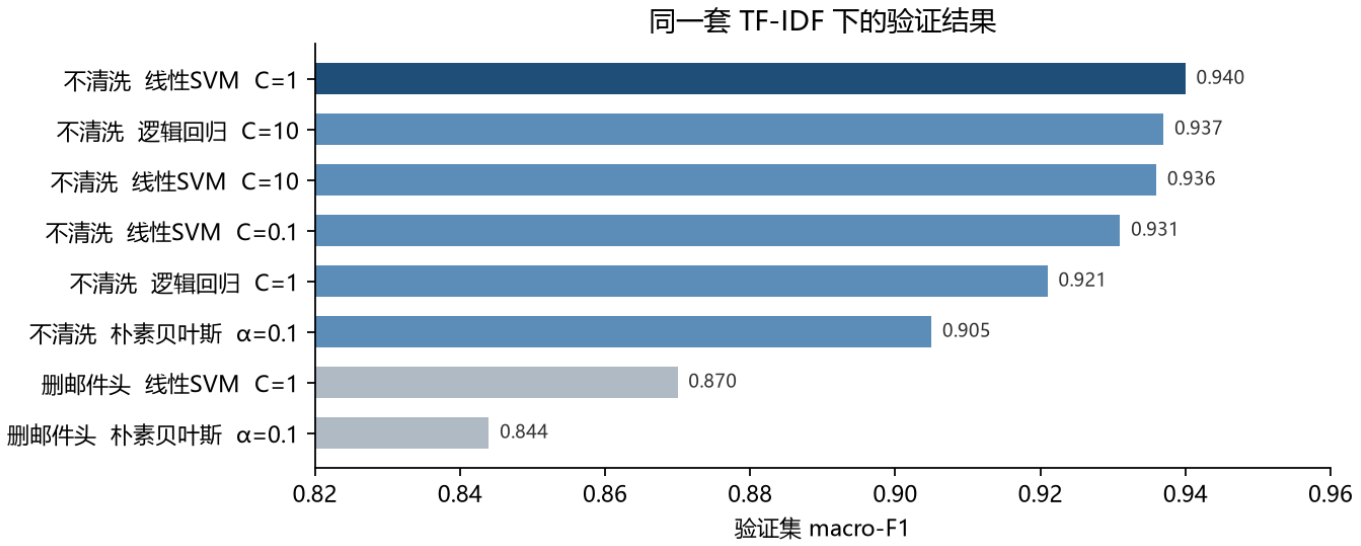
线性 SVM

0.940

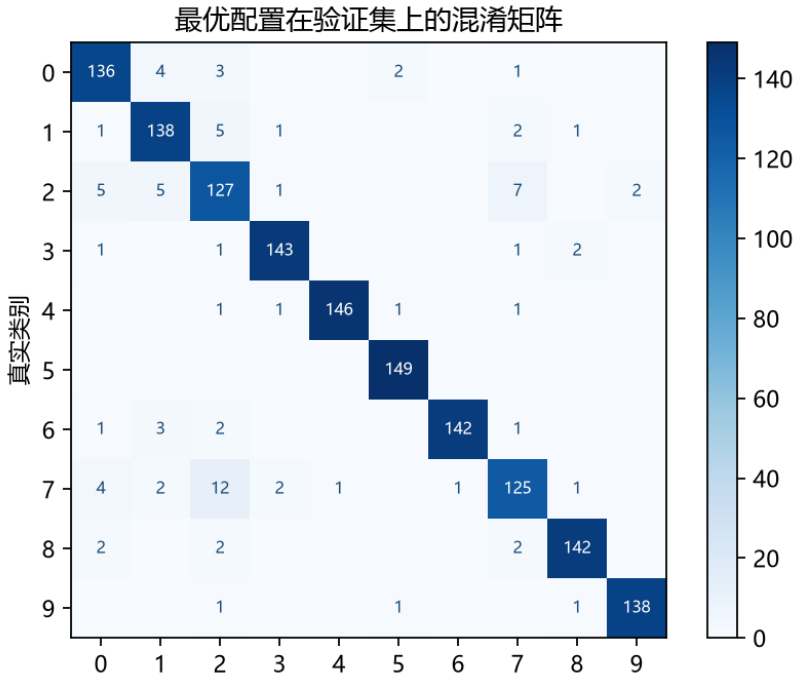
C = 1，最终选用

邮件原文以 From、Subject、Organization 开头，不是纯正文。删掉这些字段后，线性 SVM 的 macro-F1 从 0.940 降到 0.870。标题里的词本身就是类别线索，所以清洗没有带来提升。

验证集结果



误差落在哪里



对角线越深，这一类分得越准。类别 4、5、9 几乎都在对角线上，F1 约 0.98。类别 2 的 F1 约 0.84，类别 7 约 0.87，是主要误差。数据没有类别名称，报告只写编号。

锁定配置的验证准确率和 macro-F1 都是 0.940。删邮件头后最好只有 0.870，因为标题里含有类别线索。

结论

高维稀疏文本上，线性 SVM（C=1、保留原文）验证分数最高，因此用它在全部 7368 篇上重训，并提交 2457 行 prediction.csv。C=0.1 略欠拟合，C=10 略过拟合。逻辑回归要到 C=10 才接近 SVM，但更慢。